bottleneck
fine wine spirit

BERTHEZENE Cédric

Objectif : analyse des ventes et de la gestion des stocks

Phase 1 : nettoyage des données, recherche de valeurs aberrantes et détection des erreurs de formattage

Phase 2 : Analyser les données et en produire des résultats exploitables

Fichiers mis à disposition

ERP: produits du magasin

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 825 entries, 0 to 824
Data columns (total 6 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   product_id      825 non-null    int64
 1   onsale_web      825 non-null    int64
 2   price           825 non-null    float64
 3   stock_quantity  825 non-null    int64
 4   stock_status    825 non-null    object
 5   purchase_price  825 non-null    float64
dtypes: float64(2), int64(3), object(1)
memory usage: 38.8+ KB
```

WEB : produits disponibles sur le site web

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1513 entries, 0 to 1512
Data columns (total 29 columns):
 #   Column                  Non-Null Count  Dtype
---  ------                  --------------  -----
 0   sku                     1428 non-null   object
 1   virtual                 1513 non-null   int64
 2   downloadable            1513 non-null   int64
 3   rating_count            1513 non-null   int64
 4   average_rating          1430 non-null   float64
 5   total_sales             1430 non-null   float64
 6   tax_status              716 non-null    object
 7   tax_class               0 non-null      float64
 8   post_author             1430 non-null   float64
 9   post_date               1430 non-null   datetime64[ns]
 10  post_date_gmt           1430 non-null   datetime64[ns]
 11  post_content            0 non-null      float64
 12  product_type            1429 non-null   object
 13  post_title              1430 non-null   object
 14  post_excerpt            716 non-null    object
 15  post_status             1430 non-null   object
 16  comment_status          1430 non-null   object
 17  ping_status             1430 non-null   object
 18  post_password           0 non-null      float64
 19  post_name               1430 non-null   object
 20  post_modified           1430 non-null   datetime64[ns]
 21  post_modified_gmt       1430 non-null   datetime64[ns]
 22  post_content_filtered   0 non-null      float64
 23  post_parent             1430 non-null   float64
 24  guid                    1430 non-null   object
 25  menu_order              1430 non-null   float64
 26  post_type               1430 non-null   object
 27  post_mime_type          714 non-null    object
 28  comment_count           1430 non-null   float64
dtypes: datetime64[ns](4), float64(10), int64(3), object(12)
memory usage: 342.9+ KB
```

LIAISON : liaison entre ERP et WEB

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 825 entries, 0 to 824
Data columns (total 2 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   id_web      734 non-null    object
 1   product_id  825 non-null    int64
dtypes: int64(1), object(1)
memory usage: 13.0+ KB
```

Analyse exploratoire des données

- **Identifiants**
  - Suppression ”sku” car redondant avec “id_web” après jointure: WEB <-> LIAISON
  - Suppression des identiants ”id_web’ nuls : LIAISON
  - Détection et suppression des identifiants dupliqués avant et après jointure
  - Détection et suppression des identifiants sans correspondance (product_id, id_web et sku)

- **Nettoyage des données**
  - Détection et suppression des colonnes entièrement nulles
  - Minimisation des données non-pertinentes et RGPD
  - Conserver uniquement les ventes en ligne (onsale_web = 1)

- **Erreurs de formattage et incohérences**
  - Vérification champs “stock_status’ -> “instock” > 0 et “outstock” = 0 (ERP)
  - Détection et suppression des champs numériques négatifs : price, purchase_price et stock < 0
  - Remplacer id_web = 13127-1 et 14680-1 par 13127 et 14680
  - Conservation “bon_cadeau_25” car associé à un “product_id” et à des données cohérentes

- **Valeurs aberrantes**
  - Détection des prix d’achats > prix de vente (HT/TTC) : soit correction (12,65 -> 126,5) ou suppression selon la situation

Conformité RGPD

- Champs pouvant permettre d'identifier de manière directe ou indirecte un individu :
  - post_author,
  - post_date,
  - post_date_gmt,
  - post_modified,
  - post_modified_gmt,
  - post_title,
  - post_excerpt,
  - Post_parent,
  - Post_name,
  - Guid = Identifiant unique global,

Fusion ou consolidation des données

- **ERP <-> LIAISON** (*product_id*) :
  - Pas de lignes sans correspondance

- **DATASET FUSIONNE** *(id_web)* <-> **WEB** *(sku)* :
  - 3 lignes sans correspondance sur id_web et sku,
  - identifiants dupliqués après jointure

- Type de jointure **“LEFT JOIN”** :
  - Conservation des identifiants nuls
  - Détection des lignes sans correspondance

Un prix médian général autour de 23€ et d'autres à partir de 115€

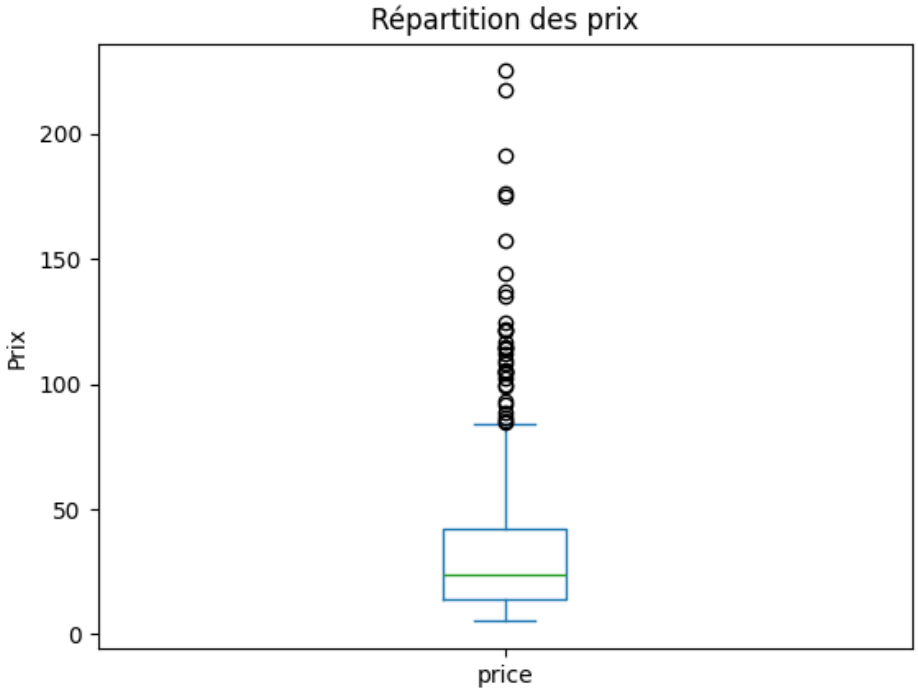

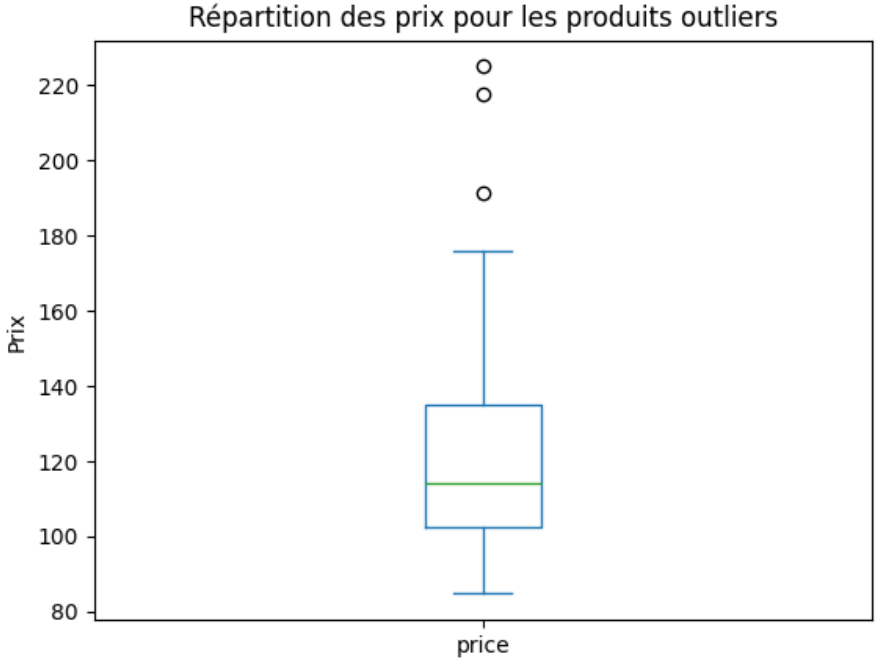

CA global : un premier constat encourageant

153 365.70€ TTC

59% des produits -> 80% du CA

Le champagne : produit de prestige dans le CA

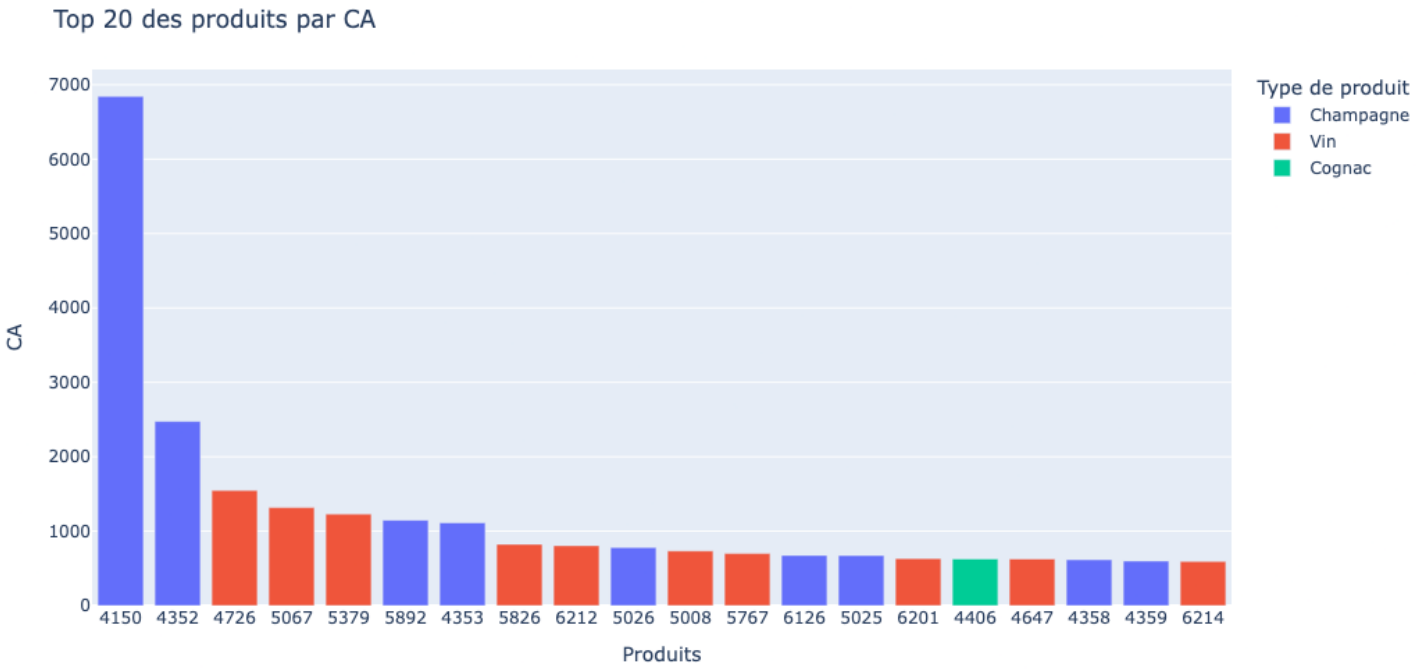

… et s’impose comme le 2nd produit le + vendu

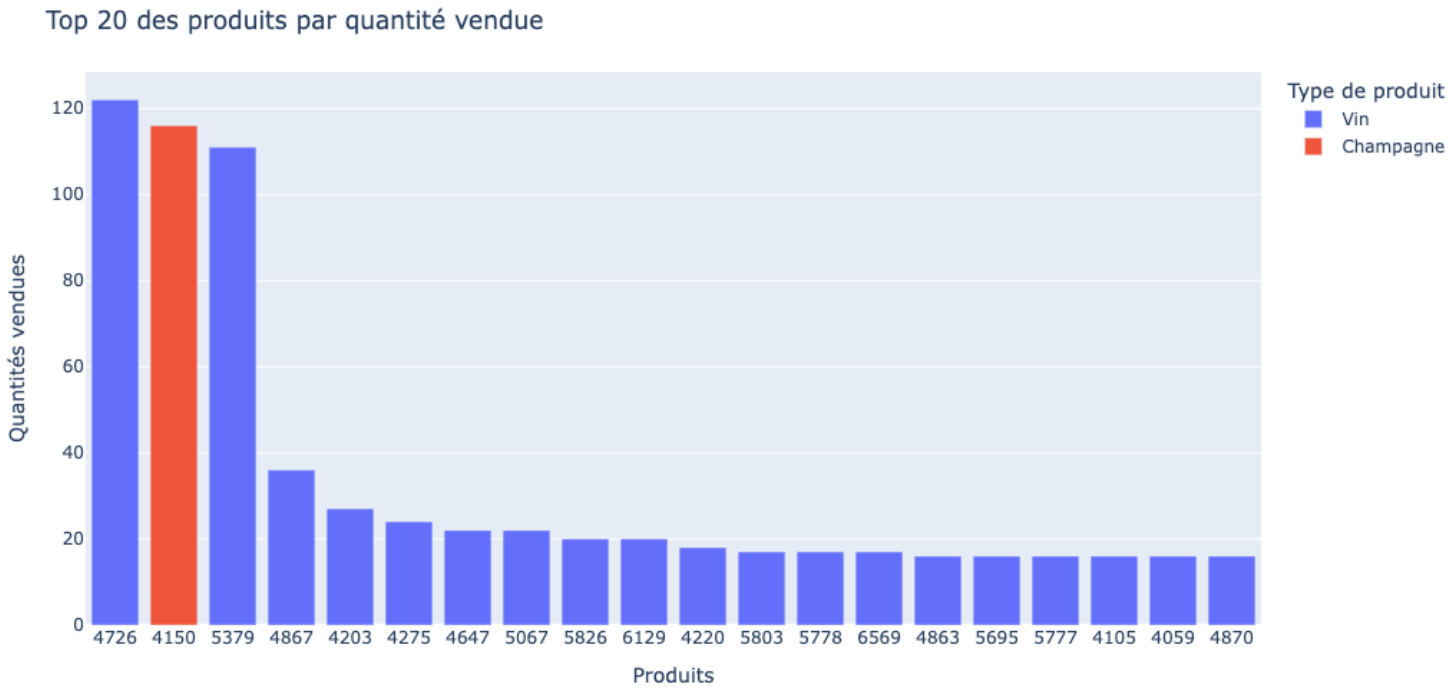

Le champagne : des stocks importants injustifiés

Des stocks cohérents

16 707 produits

Valorisation : **277 225,03€**

2,76 mois de stock sur l’ensemble des produits

Les alcools forts : champions de la rentabilité

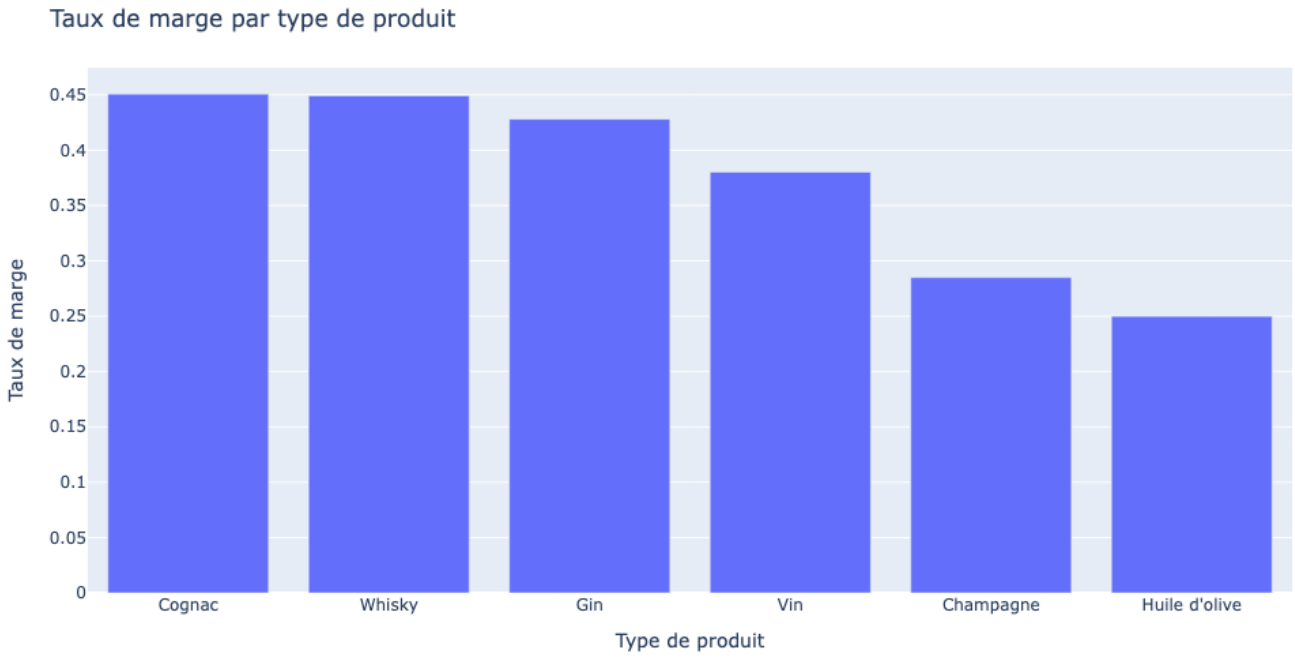

Vue d’ensemble des corrélations

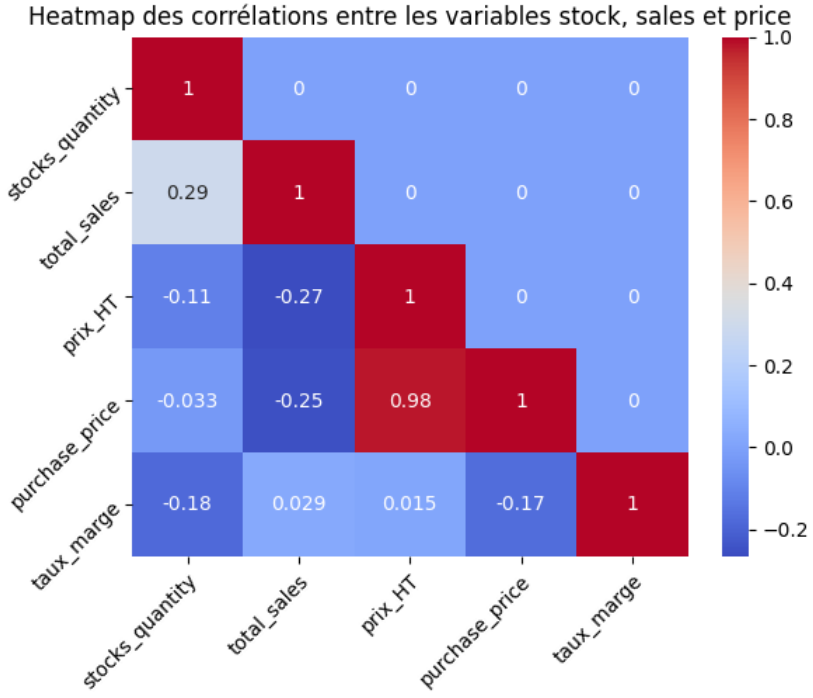

Remarques (résultats)

- **Focus sur le champagne** : une gamme trop étendue et beaucoup trop de stock

- **Pertinence de l'huile d'olive :** rentablilité la + faible et peu d'impact sur le CA et les ventes

Dataset consolidé

- 712 lignes
- 711 ‘id_web’
- 712 ‘product_id’

```
Data columns (total 21 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   product_id      712 non-null    int64
 1   onsale_web      712 non-null    int64
 2   price           712 non-null    float64
 3   stock_quantity  712 non-null    int64
 4   stock_status    712 non-null    object
 5   purchase_price  712 non-null    float64
 6   id_web          712 non-null    object
 7   virtual         712 non-null    float64
 8   downloadable    712 non-null    float64
 9   rating_count    712 non-null    float64
 10  average_rating  712 non-null    float64
 11  total_sales     712 non-null    float64
 12  tax_status      361 non-null    object
 13  product_type    712 non-null    object
 14  post_status     712 non-null    object
 15  comment_status  712 non-null    object
 16  ping_status     712 non-null    object
 17  menu_order      712 non-null    float64
 18  post_type       712 non-null    object
 19  post_mime_type  351 non-null    object
 20  comment_count   712 non-null    float64
dtypes: float64(9), int64(3), object(9)
```

Conclusion et recommendations (organisation des fichiers)

- **Identifiants**
  - Renommer “sku’ par “id_web” (+ lisible) : WEB <-> LIAISON
  - Eviter des lignes avec les trois mêmes identifiants
  - Eviter les lignes sans identifiants
  - S’assurer que les identifiants aient une correspondance valide
- **Nettoyage des données**
  - Colonnes entièrement nulles : remplir ou la supprimer
  - Minimisation des données non-pertinentes et RGPD
  - Conserver uniquement les ventes en ligne (onsale_web = 1)
- **Erreurs de formattage et incohérences**
  - S’assurer que les stocks soient cohérents : “instock” > 0 et “outstock” = 0 (ERP)
  - Empêcher la saisie de valeurs négatives
  - Respect de la codification des identifiants (13127-1 ou encore 14680-1)
  - ”bon-cadeau-25-euros” : standardisation en terme de codification ?
- **Valeurs aberrantes**
  - Eviter de rentrer des prix d’achats > prix de vente

Conclusion et recommendations (résultats)

- **Champagne : Opérations de destockage** et **arrêt de nombreuses gammes** non rentables

- Se concentrer uniquement sur les alcools

Point sur les compétences apprises

- **Nettoyage :** apprentissage de nouvelles fonctions et méthodes sur la détection des valeurs nulles, dupliquées et erreurs de formattage (.value_count(), .info() -> très utile)

- **Le + difficile :** partie nettoyage (suppression des valeurs ou modification), interprétation des corrélations entre les valeurs

- **Partie à approfondir :** nettoyage des données